

FUNDAÇÃO ESCOLA TÉCNICA LIBERATO SALZANO VIEIRA DA CUNHA

CURSO TÉCNICO DE ELETRÔNICA

KEVIN MULINARI KUHN

PAULO ROBERTO DE MOURA JÚNIOR

**WATERPI – DISPOSITIVO PARA PREVENÇÃO DE AFOGAMENTOS EM
PISCINAS RESIDENCIAIS**

Orientador: Marco César Sauer

Novo Hamburgo

2018

**KEVIN MULINARI KUHN
PAULO ROBERTO DE MOURA JÚNIOR**

**WATERPI – DISPOSITIVO PARA PREVENÇÃO DE AFOGAMENTOS EM
PISCINAS RESIDENCIAIS**

Relatório apresentado à comissão
avaliadora da Mostratec.

Orientador: Marco César Sauer.

Novo Hamburgo, outubro de 2018.

FOLHA DE APROVAÇÃO

KEVIN MULINARI KUHN

PAULO ROBERTO DE MOURA JÚNIOR

WATERPI – DISPOSITIVO PARA PREVENÇÃO DE AFOGAMENTOS EM
PISCINAS RESIDENCIAIS

FUNDAÇÃO ESCOLA TÉCNICA LIBERATO SALZANO VIEIRA DA CUNHA
CURSO TÉCNICO DE ELETRÔNICA

Novo Hamburgo, outubro de 2018.

Kevin Mulinari Kuhn

Paulo Roberto de Moura Júnior

Marco César Sauer
Professor Orientador

AGRADECIMENTOS

Ao orientador Marco César Sauer,
pela sabedoria e determinação com
que nos orientou neste trabalho.

Aos nossos pais e parentes próximos,
pela paciência, compreensão e ajuda
durante a realização do projeto.

RESUMO

Recentes dados de instituições brasileiras evidenciam a falta de soluções para a diminuição do número de afogamentos de crianças em piscinas domésticas residenciais. Com base nisso, o presente projeto visa implementar um dispositivo eletrônico que seja capaz de minimizar esse tipo de acidente, assegurando as vidas infantis. O protótipo desenvolvido realiza a detecção de crianças nas proximidades de piscinas através do processamento de imagens obtidas através de uma câmera posicionada próxima a área de interesse, e após isso, sinaliza através de avisos sonoros o que está ocorrendo lá. Para realizar o processamento das imagens, utilizamos o microcomputador de placa única Raspberry Pi 3 Model B V1.2, trabalhando junto a interface de câmera Raspberry Pi Camera V1.3. Através de métodos probabilísticos, o software tenta identificar perfis pré-treinados de seres humanos nas imagens obtidas pela câmera, identificando se há uma pessoa ou não na imagem em questão, e se ela está ou não próxima às bordas da piscina. O software que realiza as detecções foi desenvolvido na linguagem Python com auxílio da biblioteca Open Source Computer Vision Library (OpenCV), e utiliza princípios de Redes Neurais Artificiais (RNA's) para realizar a detecção de pessoas na imagem capturada. Para comprovar a eficiência dos detectores, foram realizados testes nas proximidades de piscinas em diversos tipos de situação, como a aproximação de crianças à área de detecção. Com os resultados encontrados até o momento, podemos concluir que a metodologia adotada pode auxiliar na diminuição de acidentes com crianças em piscinas residenciais.

Palavras-chave: Processamento de imagens, sistema de identificação, prevenção de acidentes.

ABSTRACT

Recent data from Brazilian institutions evidence the deficiency of solutions to decrease the drowning of children in swimming pools. Based on this information, the current research project aims to implement an electronic gadget that is able to minimize this type of accident, making children's lives safer. The developed prototype detects people in the vicinity of the pool area by processing the images obtained by a camera positioned near the area of interest. If a problem occurs, the system signals through sound alerts what is happening. To perform the image processing, we use the Raspberry Pi 3 Model B V1.2 single-board computer, working along the Raspberry Pi Camera V1.3 camera interface. Through probabilistic methods, the software tries to identify pre-trained profiles of human beings in the images obtained by the camera, identifying if there is a person or not on the image in question, and if they are close to the edges of the pool. The software that performs the probes has been developed in the Python language with aid of the Open Source Computer Vision Library (OpenCV) and uses principles of Artificial Neural Networks (ANNs) to carry out the detection of people in the captured image. To prove the efficiency of the detectors, tests were performed in the vicinity of swimming pools in different situations, such as when the children approach the detection area. With the results found so far, we can conclude that the adopted methodology can assist in the reduction of accidents with children in residential swimming pools.

Keywords: Image processing, identification system, accident prevention.

LISTA DE ILUSTRAÇÕES

Figura 1: Raspberry Pi 3 Model B.....	11
Figura 2: Raspberry Pi Camera v1.3.....	13
Figura 3: Exemplo de subtração de fundo.....	17
Figura 4: Modelo RGB.....	19
Figura 5: Modelo de cores HSV.....	19
Figura 6: Buzzer convencional.....	21
Figura 7: Diagrama Geral do Protótipo.....	23
Figura 8: Fluxograma do detector de pessoas.....	24
Figura 9: Imagem original.....	25
Figura 10: Exemplo de detecção de pessoas.....	25
Figura 11: Fluxograma do demarcador de bordas.....	26
Figura 12: Piscina.....	27
Figura 13: Resultado da detecção de borda da piscina.....	27
Figura 14: Fluxograma do detector de variação simples.....	28
Figura 15: Fluxograma do detector de pessoas.....	29
Figura 16: Imagem original 2.....	30
Figura 17: Resultado da detecção de pessoas.....	30
Figura 18: Fluxograma do subtrator de fundo.....	31
Figura 19: Fluxograma de programa 1.....	32
Figura 20: Fluxograma de programa 2.....	33
Figura 21: Fluxograma de programa 3.....	34
Figura 22: Diagrama esquemático.....	36
Figura 23: Pontos de aproximação na piscina.....	38
Figura 24: Tabela de resultados do primeiro momento de testes.....	38
Figura 25: Exemplo de detecção feita na posição 2.....	39
Figura 26: Tabela de resultados do segundo momento de testes.....	40
Figura 27: Exemplo de detecção feita na posição 8.....	41

SUMÁRIO

1 INTRODUÇÃO.....	10
1.1 Justificativa.....	10
1.2 Problema.....	10
1.3 Objetivo.....	10
2 REFERENCIAL TEÓRICO.....	11
2.1 Raspberry Pi 3 Model B.....	11
2.1.1 Especificações técnicas.....	12
2.2 Raspberry Pi Camera v1.3.....	12
2.2.1 Especificações técnicas.....	13
2.3 Python.....	14
2.4 Open Source Computer Vision Library (OpenCV).....	14
2.5 Classificadores de objetos.....	14
2.5.1 Histograma de Gradientes Orientados e Máquina de Vetor Suporte.....	15
2.5.2 Redes neurais de aprendizado profundo e Google MobileNets.....	16
2.6 Métodos de subtração de fundo em fluxos de imagem.....	17
2.6.1 Subtrator de fundo MOG2.....	18
2.7 Modelos de cores de imagem.....	18
2.7.1 Modelo RGB.....	18
2.7.2 Modelo HSV.....	19
2.7.3 Modelo em escala de cinza.....	20
2.8 Modelos de cores em piscinas residenciais.....	20
2.9 Transdutor Buzzer Piezoelétrico.....	20
3 METODOLOGIA.....	21
3.1 Classificação da pesquisa.....	21
3.2 Critérios do projeto.....	22
3.3 Análise de produtos similares.....	22
3.4 O WaterPi.....	22
3.5 Software desenvolvido.....	23
3.5.1 Detector de pessoas baseado em modelo pré treinado de Histogramas de Gradientes Orientados e Máquina de Vetor Suporte	24
3.5.2 Demarcador de borda para piscinas azuis.....	25

3.5.3 Detector de variação simples.....	27
3.5.4 Detector de pessoas pré-treinado em modelo Caffe com Google MobileNets.....	28
3.5.5 Subtrator de fundo MOG2 com detecção de bordas.....	30
3.5.6 Softwares utilizados nos testes.....	31
3.6 Testes realizados nas proximidades de piscinas.....	35
3.7 Protótipo final.....	36
4 ANÁLISE DE DADOS.....	37
5 CONCLUSÃO.....	41
REFERÊNCIAS.....	43

1 INTRODUÇÃO

1.1 Justificativa

É natural que crianças já nasçam com vontade de experimentar, e descobrir elementos e locais em que vivem. Conhecida como curiosidade, essa busca pelo conhecimento, apesar de ser importante na vida de uma criança, pode levar à uma tragédia, se não for bem supervisionada. De acordo com Goltibliatas (2015), durante a fase de crescimento, a criança ainda não compreende o que é o perigo, e ainda não aprendeu o significado do medo (algo que se é aprendido a partir da convivência com o ambiente).

Segundo o boletim da Sociedade Brasileira de Salvamentos Aquáticos, aproximadamente 54% dos casos de afogamentos de crianças entre 1 e 9 anos de idade ocorrem em piscinas domésticas, sendo a segunda causa de óbito nessa faixa etária, também. (SZPILMAN, 2015). Considerando esses dados, observa-se que há um descuido da população adulta em relação às suas crianças.

1.2 Problema

Como detectar e/ou prever acidentes com crianças em piscinas residenciais, através de uma tecnologia autônoma?

1.3 Objetivo

Desenvolver um dispositivo capaz de identificar e informar a aproximação de crianças à piscinas.


2 REFERENCIAL TEÓRICO

Neste capítulo serão descritos os principais temas que foram estudados para apropriação do conteúdo específico de processamentos de imagens e tecnologias para o desenvolvimento do sistema.

2.1 Raspberry Pi 3 Model B

De acordo com Gonçalves (2018), o Raspberry Pi é um computador de baixo custo e que tem aproximadamente o tamanho de um cartão de crédito. A sua função básica é oferecer uma alternativa barata, prática e acessível para que pessoas de várias idades possam explorar todas as capacidades da computação. Os modelos custam entre US\$ 25 e US\$ 35 fora do Brasil, porém esses preços podem ser alterados dependendo da taxa de importação.

Figura 1: Raspberry Pi 3 Model B



Fonte: (GONÇALVES, 2018).


2.1.1 Especificações técnicas

- Processador: Quad Core 1.2GHz Broadcom BCM2837 64bit;
- Memória: 1GB RAM; Rede sem fio BCM43438 e Bluetooth Low Energy (BLE) na placa;
- Porta Ethernet;
- GPIO estendido de 40 pinos;
- 4 portas USB 2.0;
- Saída estéreo de 4 polos e porta de vídeo composto;
- Suporte Full size HDMI;
- Porta da câmera CSI para conectar uma câmera Raspberry Pi;
- Porta de exibição DSI para conectar uma tela sensível ao toque do Raspberry Pi;
- Porta Micro SD para carregar o sistema operacional e armazenar dados.

2.2 Raspberry Pi Camera v1.3

De acordo com Nuttall (2016), esta câmera possui 5 megapixels de resolução, sendo capaz de captar vídeos de 1080p30, 720p60, 640x480p90 e imagens estáticas de até 2592×1944 pixels. É conectada ao terminal CSI (Camera Serial Interface), especialmente dedicado para este tipo de conexão e troca de dados. Os modelos custam em média, no Brasil, cerca de R\$50,00.

Figura 2: Raspberry Pi Camera v1.3



Fonte: (NUTTALL, 2016).

2.2.1 Especificações técnicas

- Sensor: OV5647 QSXGA;
- Resolução: 5MP;
- Imagem: 2592x1944 pixels para imagens estáticas;
- Vídeo: 1080p a 30 fps com codec H.264 (AVC) e até 90 fps vídeo em VGA;
- Comunicação via CSI;
- Tamanho do sensor: 3,67 x 2,74 milímetros;
- Lente: $f = 3,6$ mm, $f / 2.9$;
- Ângulo de visão: 54 x 41 graus;
- Campo de Visão: 2,0 x 1,33 m, a 2 m;
- Full-frame SLR lente equivalente: 35 milímetros;
- Foco fixo: 1 m ao infinito;
- Dimensões: 25x24x6mm (largura x comprimento x altura), somente da placa com a câmera;
- Peso: 3g.

2.3 Python

De acordo com Monteiro (2018), Python é uma linguagem de programação imperativa, interpretada, de alto nível e com tipagem forte e dinâmica. Ela é considerada uma linguagem multi-paradigma, pois aceita diferentes formas de programação.

Uma das principais características de Python é quanto a sua forma peculiar de escrever e, conseqüentemente, ler o código. Nela, não existem os tradicionais delimitadores formados por chaves, usados em linguagens como C, C++, C# e Java, por exemplo. Já o ponto e vírgula, usado como final de um comando nessas linguagens citadas, é opcional em Python. (MONTEIRO, 2018).

2.4 Open Source Computer Vision Library (OpenCV)

A biblioteca OpenCV foi desenvolvida pela Intel e possui mais de 500 funções. Foi idealizada com o objetivo de tornar a visão computacional acessível à usuários e programadores em áreas como a interação humano-computador em tempo real e a robótica. A biblioteca está dividida em cinco grupos de funções: Processamento de imagens; Análise estrutural; Análise de movimento e rastreamento de objetos; Reconhecimento de padrões e Calibração de câmera e reconstrução 3D. (MARENGONI; STRINGHINI, 2009).

2.5 Classificadores de objetos

Reconhecer significa conhecer de novo, e isto implica num processo onde existe algum conhecimento prévio e algum tipo de armazenamento do conhecimento sobre o objeto a ser reconhecido. Para fazer o reconhecimento, um sistema de visão necessita uma base de conhecimento dos objetos a serem

reconhecidos, esta base de conhecimento pode ser implementada diretamente no código, através, por exemplo, de um sistema baseado em regras, ou esta base de conhecimento pode ser aprendida a partir de um conjunto de amostras dos objetos a serem reconhecidos utilizando técnicas de aprendizado de máquina. (MARENGONI; STRINGHINI, 2009).

O reconhecimento de objetos é uma das principais funções da área de visão computacional e está relacionado diretamente com o reconhecimento de padrões. Um objeto pode ser definido por mais de um padrão (textura, forma, cor, dimensões, etc.) e o reconhecimento individual de cada um destes padrões pode facilitar o reconhecimento do objeto como um todo. (MARENGONI; STRINGHINI, 2009).

O padrão do corpo humano é único e bastante específico, sendo composto principalmente por: dois braços, duas pernas, caixa torácica e cabeça.

2.5.1 Histograma de Gradientes Orientados e Máquina de Vetor Suporte

O Histograma de Gradientes Orientados (HOG¹) foi proposto por Dalal e Triggs (2005), e geralmente é utilizado em reconhecimento de padrões e processamento de imagens para detectar ou reconhecer objetos. O cálculo desse descritor é computacionalmente complexo, onde a imagem é dividida em células (janelas de tamanho pequeno) não sobrepostas e para cada célula é calculado o histograma de gradientes orientados.

Na visão computacional, descritores visuais ou descritores de imagem (ou seja, HOG) são descrições das características visuais dos conteúdos em imagens. Eles descrevem características elementares, como a forma, a cor, a textura ou o movimento, entre outros. Portanto, os descritores de HOG apenas caracterizam a cena. Já a Máquina de Vetor Suporte (SVM²) é um conjunto de métodos de aprendizado supervisionados usados para classificação de detecções, ou seja, a saída do HOG é a entrada do SVM.

¹ Histogram of Oriented Gradients.

² Support Vector Machine.

2.5.2 Redes neurais de aprendizado profundo e Google MobileNets

A técnica de redes neurais artificiais tenta simular o cérebro humano, mas o cérebro processa informações de uma forma totalmente diferente do computador digital convencional.

Na sua forma mais geral, uma rede neural é uma máquina que é projetada para modelar a maneira como o cérebro realiza uma tarefa particular ou função de interesse eletrônicos ou é simulada por programação em um computador digital. Para alcançarem bom desempenho, as redes neurais empregam uma interligação maciça de células computacionais simples denominadas de “neurônios” ou “unidades de processamento”. Podemos então oferecer a seguinte definição de uma rede neural vista como uma máquina adaptativa: Uma rede neural é um processador maciçamente paralelamente distribuído de unidades de processamento simples, que têm a propensão natural para armazenar conhecimento experimental e torná-lo disponível para o uso (GOUVEA et al., 2017).


Embora muitas dessas tecnologias, como reconhecimento de objeto, marco, logotipo e texto, sejam fornecidas para dispositivos conectados à Internet, o poder computacional cada vez maior dos dispositivos móveis pode permitir a entrega dessas tecnologias nas mãos de usuários de dispositivos móveis, a qualquer hora, em qualquer lugar, independentemente da conexão com a Internet. No entanto, o reconhecimento visual no dispositivo e em aplicativos incorporados apresenta muitos desafios: os modelos devem ser executados rapidamente com alta precisão em um ambiente com recursos limitados, fazendo uso de computação, energia e espaço limitados. O MobileNets foi projetado para maximizar com eficácia a precisão, ao mesmo tempo em que cuida dos recursos restritos para um aplicativo incorporado no dispositivo. Os MobileNets são modelos pequenos, com baixa latência e baixo consumo de energia parametrizados para atender às restrições de recursos de vários casos de uso. Eles podem ser construídos para classificação, detecção, incorporação e segmentação, semelhante a como outros modelos populares de grande escala que são usados (HOWARD; ZHU, 2017).

2.6 Métodos de subtração de fundo em fluxos de imagem

De acordo com Ferreira (2012), o método de subtração de imagens funciona em partes. Inicialmente, cada quadro da sequência é subtraído do fundo. Ao mesmo tempo, o quadro atual pode ser utilizado para atualização do fundo. Depois, a imagem resultante da subtração é segmentada com o fim de produzir uma imagem binária que ressalte as regiões em movimento da imagem.

Cada nova imagem da sequência é subtraída da imagem de fundo. Ao mesmo tempo, a imagem atual é utilizada para atualizar a imagem de fundo. Depois, a imagem resultante da diferença é segmentada para produzir uma imagem binária, que indica as regiões da imagem onde se apresenta o movimento. Finalmente, o objeto em movimento é detectado. (FERREIRA, 2012).

Figura 3: Exemplo de subtração de fundo



Fonte: (FERREIRA, 2012).

A subtração de fundo funciona também como um detector de variação, logo, conseguimos utiliza-lo para auxiliar na detecção de pessoas em nossa área de interesse.

2.6.1 Subtrator de fundo MOG2

De acordo com Zivkovic (2004), o MOG2 é também um Algoritmo de Segmentação de Fundo / Primeiro Plano baseado em Mistura Gaussiana. Uma característica importante deste algoritmo é que seleciona o número apropriado de distribuição gaussiana para cada pixel.

Ele fornece melhor adaptabilidade a cenas variadas devido a mudanças de iluminação, etc.


2.7 Modelos de cores de imagem

O objetivo do modelo de cor é facilitar a especificação de cores em algum padrão. A especificação é feita em um sistema de coordenadas no qual cada cor é representada por um único ponto.

2.7.1 Modelo RGB

É composto por três valores, os quais representam uma escala para cada cor, vermelho (*red*), verde (*green*) e azul (*blue*). Desta forma, qualquer cor pode ser definida em função de suas três cores primárias. É o modelo de cor mais utilizado para monitores de vídeo e câmeras. (BORBA, 2015).


Considerando que intensidade é o nível de luz (claro ou escuro) em um pixel, no modelo RGB essa intensidade então será dada pelo módulo da distância da origem ao pixel considerado.

Figura 4: Modelo RGB

Fonte: (GATTAS, 2007).

2.7.2 Modelo HSV

HSV é a abreviatura para o sistema de cores formadas pelas componentes *Hue* (tonalidade), *Saturation* (Saturação) e *Value* (Valor). Esse sistema também é conhecido como HSB (*Hue*, *Saturation* e *Brightness* - Tonalidade, Saturação e Brilho, respectivamente). Esse sistema de cores define o espaço de cor, utilizando seus três parâmetros: tonalidade ou matiz, saturação e valor ou brilho. (KONWAR et al., 2014).

Figura 5: Modelo de cores HSV

Fonte: (KONWAR et al., 2014).

2.7.3 Modelo em escala de cinza

Para representar imagens a preto-e-branco (e com tons intermédios de cinzento) basta associar a cada pixel um valor numérico numa escala de tons. De acordo com Moreira (2000), se quisermos, por exemplo, uma escala com 256 tons de cinza (do preto absoluto ao branco absoluto) podemos associar a cada pixel um valor inteiro não-negativo de um byte. Convencionamos que o valor 0 corresponde ao preto e 255 corresponde ao branco; os valores intermédios correspondem aos tons de cinzentos.

2.8 Modelos de cores em piscinas residenciais

De acordo com Sayegh (2009), a configuração de cor de piscinas residenciais deve ser clara, se não elimina a iluminação subaquática, junto com a iluminação ambiente, que fica altamente prejudicada quando a piscina é escura. Por esse motivo, as piscinas residenciais normalmente possuem a coloração azul ou branca, pois além de não atrapalhar a iluminação, a coloração da água tende ao azul e não parece “suja”, graças ao reflexo produzido da água com o fundo da piscina.

2.9 Transdutor Buzzer Piezoelétrico

Podemos exemplificar o Buzzer como sendo um pequeno alto falante, e, para funcionar, é necessário que ele receba uma tensão a uma certa frequência. Com isso, a célula piezoelétrica que tem dentro dele irá vibrar nesta frequência, produzindo assim um som. E isto ocorre, pois, as ondas sonoras são produzidas por vibrações. (MARQUES et al., 2016).

Figura 6: Buzzer convencional



Fonte: (MOTA, 2018).

3 METODOLOGIA

Neste capítulo serão descritos todos os métodos e procedimentos utilizados no desenvolvimento do sistema para a detecção de crianças nas proximidades de piscinas residenciais azuis, o qual tem a função de avisar aos pais e/ou responsáveis em caso de perigo de afogamento. Serão explicadas todas as etapas de desenvolvimento do software para o dispositivo, do sistema de alerta e dos testes realizados para escolher as melhores soluções, como também, para comprovar a eficácia do sistema.

3.1 Classificação da pesquisa

De acordo com SOUZA (2013), a pesquisa possui caráter tecnológico por ser uma pesquisa científica aplicada, visando a materialização ou estudo de viabilização de um protótipo.

3.2 Critérios do projeto

Neste item, apresentam-se os critérios adotados durante a elaboração da pesquisa:

1. Ser portátil e versátil, de modo que possa ser utilizado na maioria das piscinas residenciais que possuam bordas azuis;
2. Operar de forma autônoma, com mínima ou nenhuma interferência de seres humanos nos processos de detecções;
3. Garantir a liberdade de quem utiliza as piscinas residenciais como lazer, isto é, optar por não utilizar métodos que interfiram na utilização nominal da piscina.

3.3 Análise de produtos similares


O iSwimband é uma “tiara” adaptada à testa da criança. Com ela, é possível sincronizar via Bluetooth o celular do pai ou responsável, que receberá um alerta caso a criança fique submersa por mais tempo que o normal na água. Pode também ser ajustada para avisar quando uma criança que ainda não nada se aproximar da água. (EMPRESA..., 2014). Porém, percebe-se que por ser uma criança, há a chance de retirada da tiara a qualquer momento, ato que pode ocasionar em um acidente, pois não há como saber onde a criança estará.

3.4 O WaterPi

O dispositivo desenvolvido utiliza um microcomputador de placa única Raspberry Pi 3 Model B junto ao módulo de câmera Raspberry Pi Camera Rev 1.3, para capturar imagens em tempo real e processá-las através do software desenvolvido, como também, utiliza alguns periféricos para a sinalização com

avisos sonoros (Transdutor Buzzer Piezoelétrico), avisos luminosos (LED's³) e controle do dispositivo (botões de contato momentâneo). O programa detecta as bordas da piscina de forma autônoma, através da cor azul, e se houver movimentação na área que é coberta pelo ângulo da câmera, ele procura perfis de seres humanos onde há essa variação. Caso identifique um ser humano presente na captura, ele compara a posição da detecção em relação às bordas da piscina, para informar através do sistema de avisos sonoros e luminosos, se há ou não um possível risco de afogamento.

Figura 7: Diagrama Geral do Protótipo



Fonte: os autores (2018).

3.5 Software desenvolvido

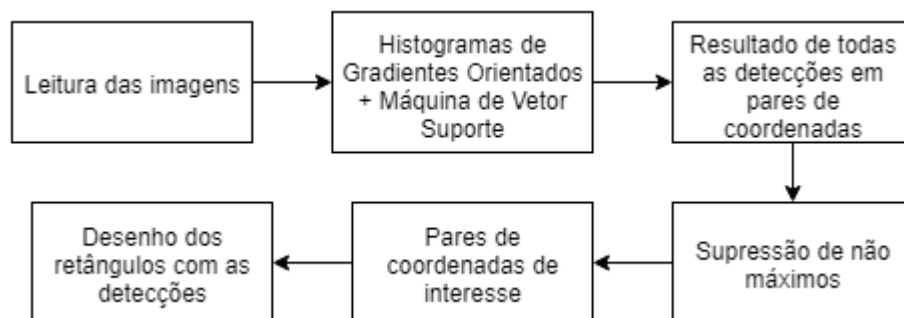
Ao longo da pesquisa, foram desenvolvidos e utilizados diferentes algoritmos até que se chegou nas implementações finais. Para a programação, utilizou-se a linguagem Python 3 junto a Open Source Computer Vision Library 3.4.2 (OpenCV) para processar imagens. Aqui será descrito todo o funcionamento desses algoritmos separadamente e nas aplicações em conjunto.

³ Light-Emitting Diodes.

3.5.1 Detector de pessoas baseado em modelo pré treinado de Histogramas de Gradientes Orientados e Máquina de Vetor Suporte

Para verificar se a tecnologia de classificação de objetos baseada em Histogramas de Gradientes Orientados e Máquina de Vetor Suporte poderia satisfazer as necessidades da pesquisa, um algoritmo foi desenvolvido, de forma que houvesse a possibilidade de realizar alguns testes básicos em imagens previamente capturadas nas proximidades de piscinas. O objetivo era rodar o algoritmo dentro do microcomputador, para saber se ele poderia detectar pessoas com precisão usando esta implementação. Dentro da biblioteca OpenCV, há funções de Histogramas de Gradientes Orientados e Máquina de Vetor Suporte implementadas previamente.

Figura 8: Fluxograma do detector de pessoas




Fonte: os autores (2018).

Figura 9: Imagem original



Fonte: os autores (2018).

Figura 10: Exemplo de detecção de pessoas



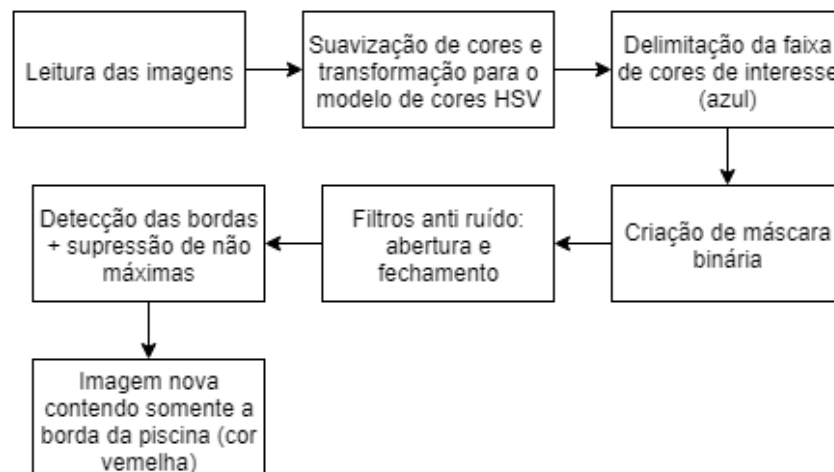
Fonte: os autores (2018).

3.5.2 Demarcador de borda para piscinas azuis

As piscinas residenciais de plástico possuem uma faixa de cores bem definida, em sua maioria essa faixa representa a cor azul, muito utilizada em

fundos e/ou bordas. Para detectar a borda da piscina em relação a outros objetos e formas do ambiente, o algoritmo utiliza essa faixa de cor azul para marcar os contornos, isto é, ele cria uma imagem nova, apenas com a demarcação do contorno, para que possa ser utilizada posteriormente em comparações de proximidade do ser humano com a borda. Os testes básicos com esse algoritmo foram feitos em imagens previamente capturadas nas proximidades de piscinas, no qual ele deveria identificar corretamente a piscina em questão, garantindo seu funcionamento.

Figura 11: Fluxograma do demarcador de bordas



Fonte: os autores (2018).

Figura 12: Piscina



Fonte: os autores (2018).

Figura 13: Resultado da detecção de borda da piscina



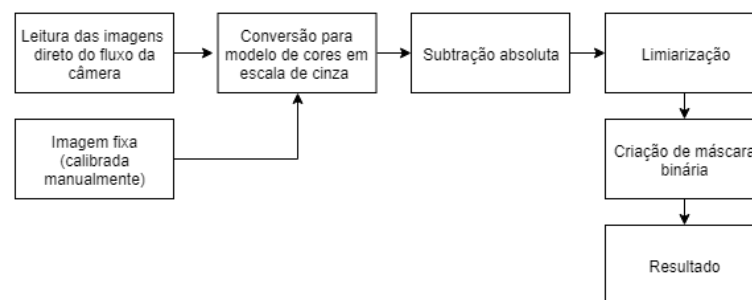
Fonte: os autores (2018).

3.5.3 Detector de variação simples

O Raspberry Pi possui uma capacidade de processamento limitada para trabalhar continuamente processando imagens, testes básicos realizados no dispositivo apontaram que mesmo em resoluções baixas (640x480) seu

processador atinge o uso máximo (100%). Em princípio, um detector de variação foi desenvolvido para funcionar como condição de execução do algoritmo geral, isto é, para calcular uma média aproximada de variação entre duas imagens, uma obtida direto do fluxo contínuo da câmera e outra calibrada manualmente apenas uma vez, e após isso, comparar essa média com um valor mínimo definido (5%, por exemplo), indicando se houve variação significativa ou não.

Figura 14: Fluxograma do detector de variação simples

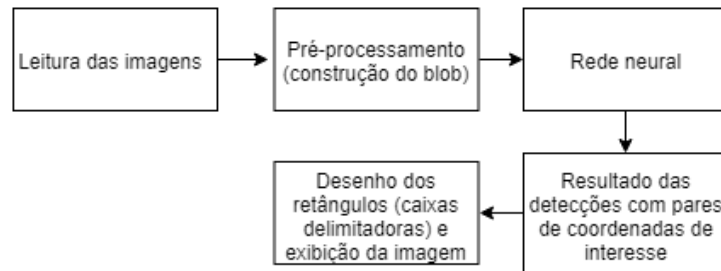


Fonte: os autores (2018).

3.5.4 Detector de pessoas pré-treinado em modelo Caffe com Google MobileNets

Em alternativa ao modelo de Histogramas de Gradientes Orientados e Máquina de Vetor Suporte previamente discutido, uma rede neural pré-treinada baseada no método do Google Mobile Nets foi utilizada, implementada através de métodos disponíveis na biblioteca OpenCV, usando o modelo Caffe. O objetivo inicial foi estabelecer um segundo método para realizar as detecções, já que em testes básicos, o outro modelo demonstrou-se ineficiente.

Figura 15: Fluxograma do detector de pessoas




Fonte: os autores (2018).

Figura 16: Imagem original 2



Fonte: os autores (2018).

Figura 17: Resultado da detecção de pessoas

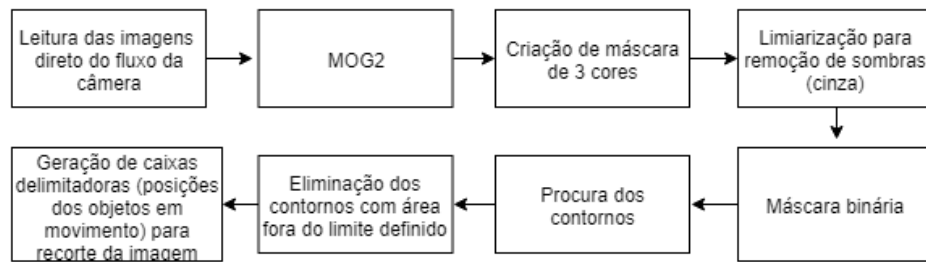


Fonte: os autores (2018).

3.5.5 Subtrator de fundo MOG2 com detecção de bordas

Para facilitar o funcionamento dos detectores de pessoas, que em momentos anteriores à aplicação deste recurso realizavam detecções em todo o corpo da imagem, implementou-se um subtrator de fundo MOG2 disponível na biblioteca OpenCV. Esse algoritmo exerce a função de fornecer informações sobre a posição de objetos que estejam se movendo em um fluxo de vídeo, criando uma máscara em 3 cores: preto, cinza e branco. Com base nessa máscara, realiza-se uma detecção de contornos para localizar a área de interesse, isto é, a área onde deveriam ser feitas as detecções. Foi possível, também, estabelecer um limite mínimo e máximo para o tamanho desses contornos, permitindo que a subtração de fundo funcione como um detector de variação, dispensando a utilização da implementação anterior. Com o recurso de demarcação de sombras pela cor cinza na máscara criada pelo MOG2, uma correção nesta interferência de sombras foi implementada para que só restassem na máscara, a localização dos objetos que estão se movendo (pessoas).

Figura 18: Fluxograma do subtrator de fundo

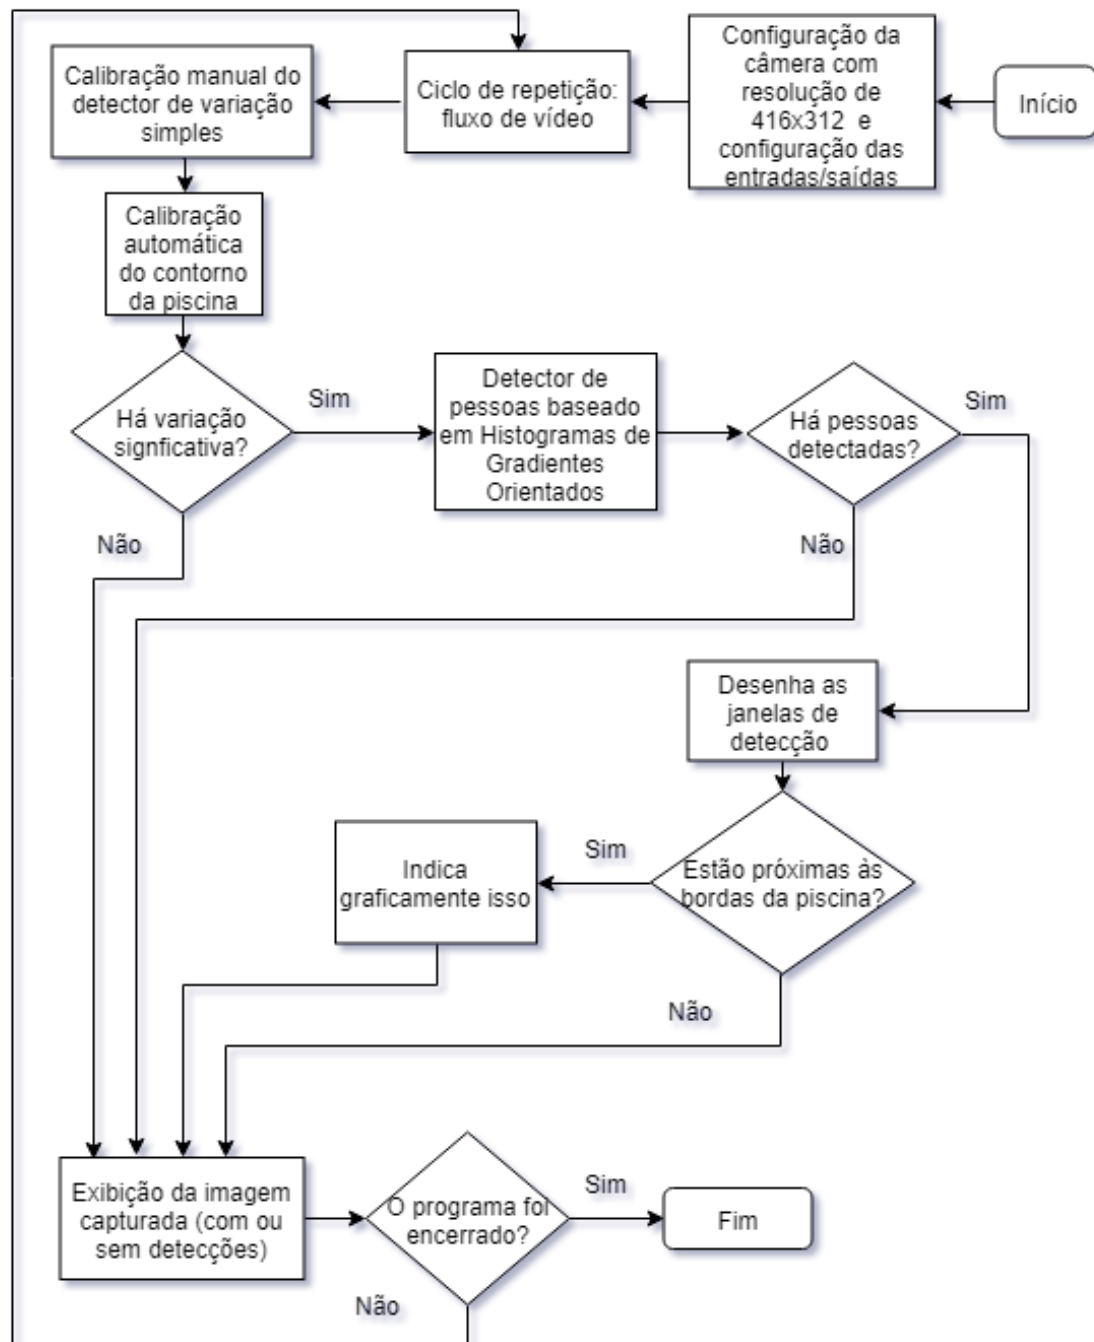


Fonte: os autores (2018).

3.5.6 Softwares utilizados nos testes

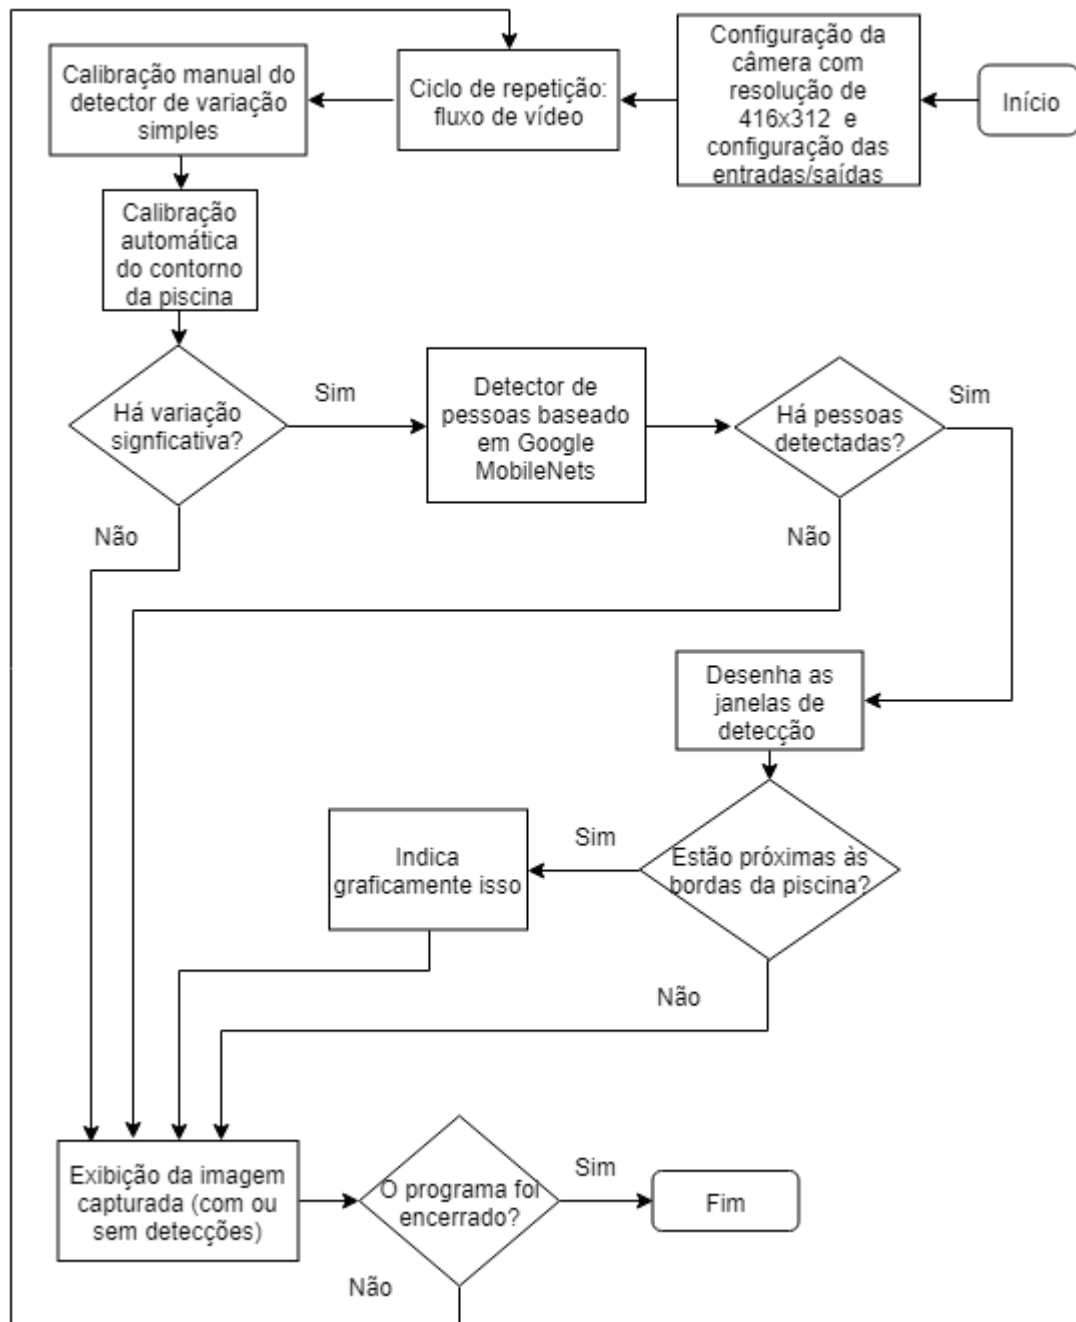
Para realizar os testes em tempo real com o dispositivo, as aplicações citadas anteriormente foram utilizadas em quatro tipos de modelo que serão representados nos fluxogramas a seguir.

Figura 19: Fluxograma de programa 1



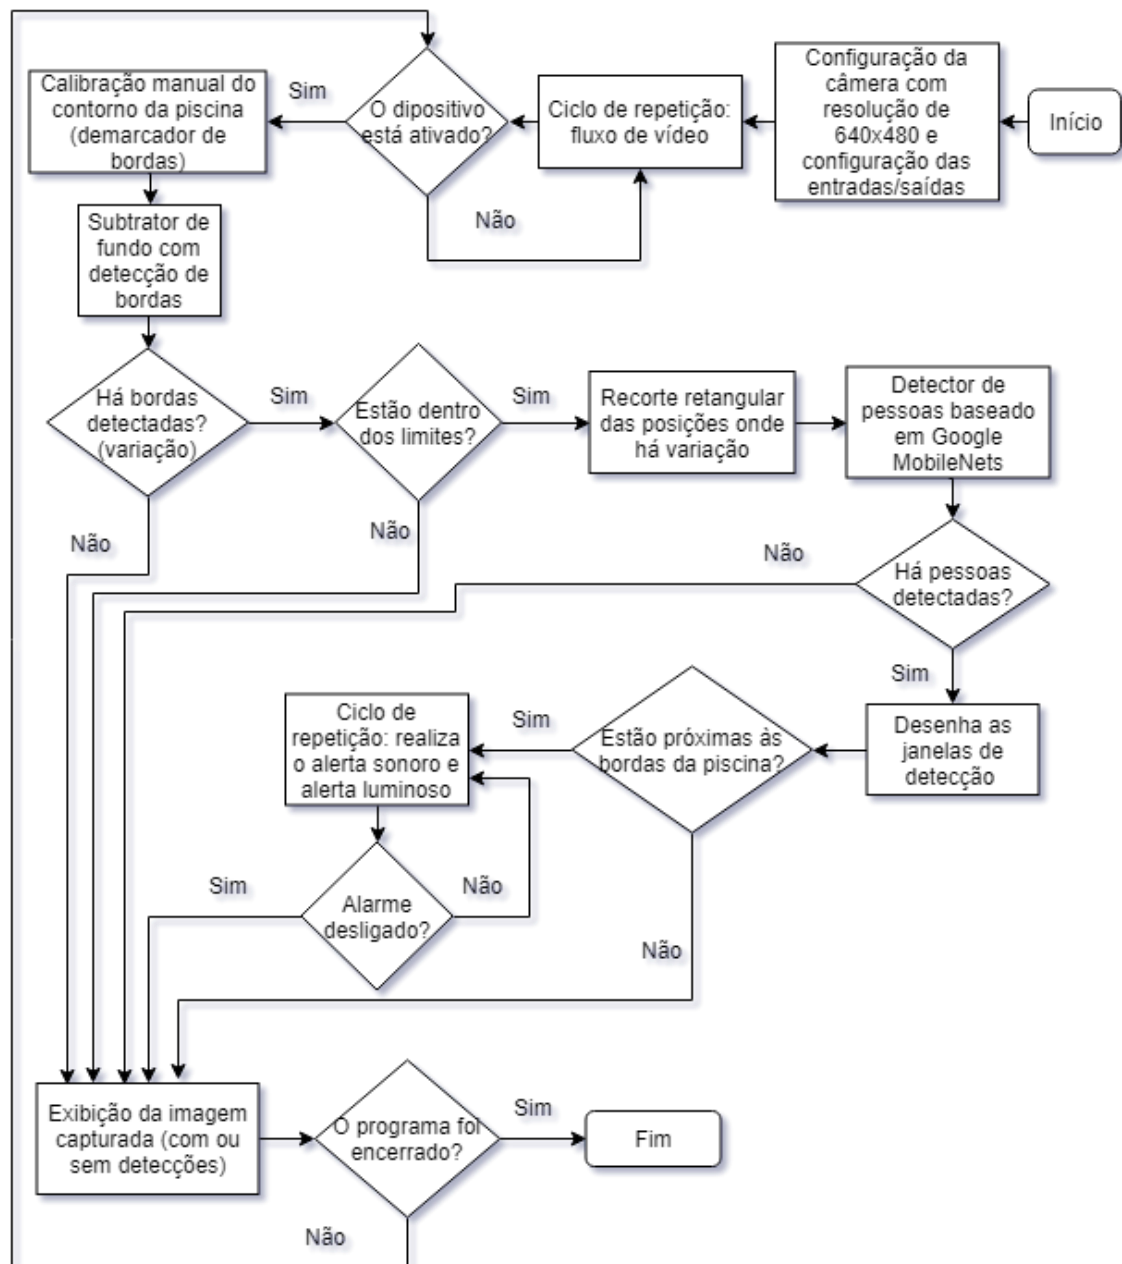
Fonte: os autores (2018).

Figura 20: Fluxograma de programa 2



Fonte: os autores (2018).

Figura 21: Fluxograma de programa 3



Fonte: os autores (2018).

Para os dois primeiros modelos, não há diferença alguma entre eles, exceto pela mudança no método de detecção de pessoas. Comparando os dois primeiros modelos com o terceiro, algumas mudanças significativas foram feitas,

como a configuração de resolução maior para captura das imagens, implementação do subtrator de fundo e do sistema de alarmes.

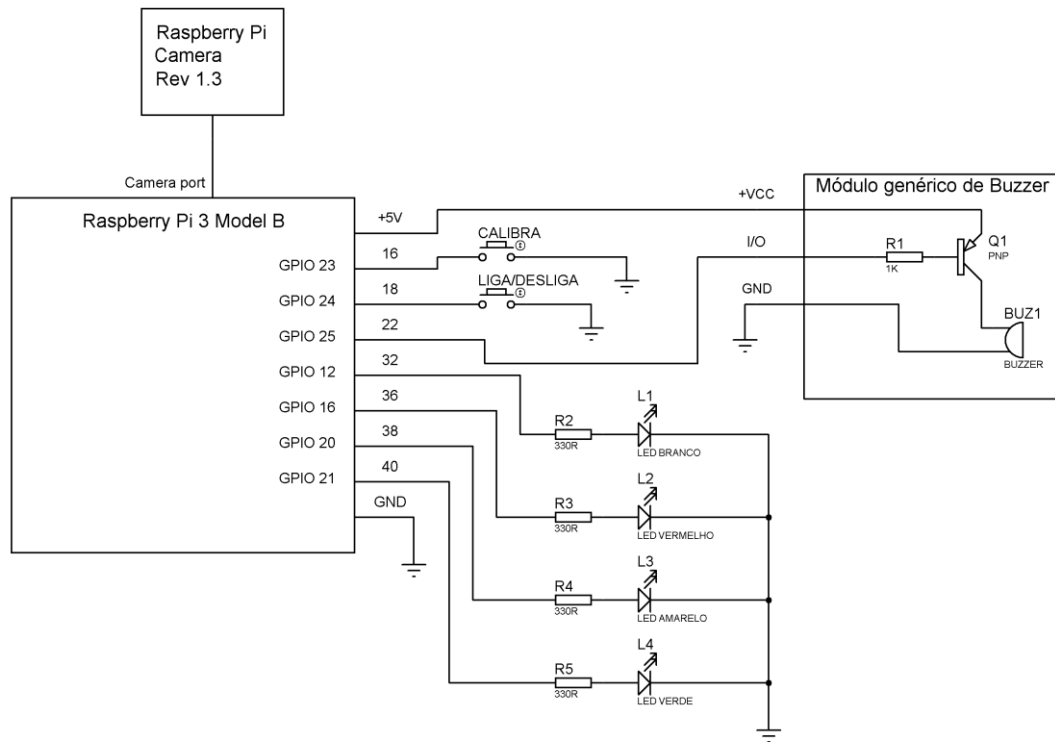
3.6 Testes realizados nas proximidades de piscinas

Para os diferentes modelos de software apresentados, foram realizados diferentes testes. Os dois primeiros modelos foram testados, em primeiro momento, apenas com crianças voluntárias caminhando ao redor da piscina, para comparar quais dos dois métodos obteria o melhor desempenho nas detecções. Nesses testes, o modelo de detecção de pessoas baseado em Histograma de Gradientes Orientados se mostrou incapacitado para a utilização em tempo real de pessoas, por ser mais lento e acusar muitos falsos-positivos (detecções incorretas) quando comparado à implementação baseada em Google MobileNets. Porém, o programa 2 também apresentou problemas em detecções de crianças que estavam em uma distância maior, para isso, associou-se o problema à baixa resolução que era utilizada na configuração da câmera. Com isso, decidiu-se utilizar o segundo método para realizar as detecções (baseado em Google MobileNets) e prosseguir com os testes seguintes utilizando somente este modelo.

Para comprovar a eficácia do dispositivo, foram realizados dois testes utilizando o programa 3, onde pretendia-se aproximar crianças da área de detecção (bordas da piscina) de três maneiras diferentes: caminhando, engatinhando e rastejando; mostrando que o dispositivo poderia funcionar em todas essas maneiras. A mesma piscina foi utilizada para ambos os testes e o protótipo foi posicionado bem à frente dela, com a abertura da câmera cobrindo toda a área.

3.7 Protótipo final

Figura 22: Diagrama esquemático



Fonte: os autores (2018).

Os módulos Raspberry Pi Camera e Raspberry Pi 3 representam, respectivamente, a câmera e o microcomputador utilizados no sistema.

Os LEDs utilizados representam situações de interesse para o sistema: O LED branco serve para indicar se o dispositivo está ligado ou desligado; O LED verde, indica se nenhuma pessoa está posicionada em nossa área de interesse (redor da piscina); O LED amarelo é acionado caso alguma pessoa se posicione perto da piscina, mas fora da área de risco (bordas); por último, o LED vermelho será acionado junto ao dispositivo sonoro, caso alguma pessoa se encontre na área de risco.

Dois botões foram utilizados com funções diferentes no sistema. O primeiro botão (liga/desliga), é responsável por ligar e desligar o dispositivo. O segundo botão (calibra), tem como princípio ativar a função de demarcação de borda, para que a detecção da piscina só ocorra quando necessário.

O módulo de Buzzer está sendo utilizado como sistema de avisos sonoros. Ele possui um transistor que permite a controle do Buzzer sem exigir muita corrente das saídas digitais do Raspberry Pi.

4 ANÁLISE DE DADOS

Neste item, serão descritos e analisados os dados levantados com o sistema durante os testes realizados nas proximidades de piscinas. Nos dois momentos de teste, foram elaboradas tabelas para comparação e análise de possíveis falhas em detecções nas aproximações das crianças. Na representação da figura 23 estão os pontos da área da piscina onde foram feitas as aproximações.

No primeiro momento de teste, houve a participação de duas crianças, um menino e uma menina, os quais se submeteram às aproximações das bordas da piscina partindo de 8 pontos diferentes, se movendo de duas maneiras distintas, caminhando e engatinhando. Apenas o sistema de avisos luminosos foi testado neste dia, pois o transdutor buzzer piezoelétrico, para avisos sonoros, ainda não estava disponível para a utilização. No total foram realizados 22 testes pela tarde e o clima do ambiente estava ensolarado. O resultado dos testes pode ser observado nas figuras 24.

Figura 23: Pontos de aproximação na piscina



Fonte: os autores (2018).


Figura 24: Tabela de resultados do primeiro momento de testes

POSIÇÃO	MENINA: CAMINHANDO	MENINO: ENGATINHANDO	POSIÇÕES	MENINO E MENINA: ENGATINHANDO
1	OK	OK	2 e 6	OK
2	OK	OK	5 e 1	OK
3	OK	OK	3 e 1	OK
4	OK	OK	2 e 2	OK
5	OK	OK	6 e 6	FALHA
6	OK	FALHA	7 e 7	OK
7	OK	OK		
8	OK	OK		

Fonte: os autores (2018).

Analisando os resultados, a posição 6 apresentou erro em mais de um tipo de aproximação. Uma possibilidade para a ocorrência destas falhas foi o mal posicionamento da câmera em relação à borda esquerda da piscina, que foi constatado observando imagens que foram salvas durante as detecções. Nos demais testes, as detecções obtiveram êxito. Um exemplo de detecção na posição 2 pode ser visualizado na figura 25.

Figura 25: Exemplo de detecção feita na posição 2



Fonte: os autores (2018).

No segundo momento de teste, houve a participação de apenas um menino, o qual se submeteu às aproximações das bordas da piscina partindo de 8 pontos diferentes, movimentando-se de três maneiras distintas, caminhando, engatinhando e rastejando. Os sistemas de avisos sonoros e luminosos foram testados neste momento. No total foram realizados 24 testes pela manhã e o clima do ambiente estava nublado. O resultado dos testes pode ser observado na figura 26.

Figura 26: Tabela de resultados do segundo momento de testes

POSIÇÃO	CAMINHANDO	ENGATINHANDO	RASTEJANDO
1	FALHA	FALHA	OK
2	OK	OK	OK
3	OK	OK	OK
4	OK	OK	OK
5	OK	OK	OK
6	OK	OK	OK
7	OK	OK	OK
8	FALHA	FALHA	OK

Fonte: os autores (2018).

Analisando os resultados, as posições 8 e 1 apresentaram erro em dois dos três tipos de aproximação. Levando-se em consideração que são as posições mais afastadas do dispositivo e que nas detecções com as crianças engatinhando não houve problema, uma possível causa do erro foi constatada como a incorreta delimitação da janela de detecção pelo subtrator de fundo, isto é, o detector de pessoas pode ter sido executado em uma janela que não continha todo o corpo das crianças, falhando na detecção. Um exemplo de detecção na posição 8 pode ser visualizado na figura 27.

Figura 27: Exemplo de detecção feita na posição 8



Fonte: os autores (2018).

Considerando os dois momentos de testes, o percentual de detecções corretas equivale a 86,96% do total. O software desenvolvido conseguiu identificar a demarcação da piscina em todos os testes realizados e o sistema de avisos sonoros e luminosos funcionaram como o previsto.

5 CONCLUSÃO

Com os resultados apresentados nos testes, comprovou-se que o dispositivo desenvolvido consegue realizar a detecção de criança, da piscina e da interação de proximidade entre ambas, para emitir os alertas, com precisão de 89,96% nos 46 testes realizados. O detector de pessoas baseado em redes neurais (Google MobileNets) apresentou-se como uma boa solução para realizar a identificação das crianças na área da piscina. A identificação das bordas da piscina pela faixa de cor azul se mostrou suficiente para realização das comparações de proximidade.

Portanto, o dispositivo desenvolvido se mostrou funcional e pode auxiliar na prevenção de afogamentos com crianças em piscinas residenciais, operando de forma autônoma, sem interferir na utilização da piscina para o lazer, isto é, nada foi acoplado à piscina ou à criança para realizar as detecções, como também, o protótipo pode ser desligado a qualquer momento para a utilização da piscina.

Como sugestão de possíveis implementações futuras que agreguem ao projeto, pode-se citar a realização de melhorias no treinamento das redes neurais utilizadas (para aumentar a velocidade de detecção), a realização de mais testes que comprovem a eficácia do dispositivo, e a melhoria do sistema de avisos sonoros, tornando mais fácil a identificação quando houver risco na piscina para avisar aos pais e/ou responsáveis.

REFERÊNCIAS

BORBA, Victor Ubiracy. Estudo Comparativo de Algoritmos de Extração de Fundo. 2015.

BORGES, Luiz Eduardo. **Python para Desenvolvedores: Aborda Python 3.3**. Novatec Editora, 2014.

DALAL, Navneet; TRIGGS, Bill. Histograms of oriented gradients for human detection. In: **Computer Vision and Pattern Recognition, 2005. CVPR 2005. IEEE Computer Society Conference on**. IEEE, 2005. p. 886-893.

EMPRESA americana cria dispositivo que previne afogamento de crianças. Disponível em: <<https://acontecendoaqui.com.br/tech/empresa-americana-cria-dispositivo-que-previne-afogamento-de-criancas>>. Acesso em: 30 abr. 2018.

FERREIRA, Camilo Sánchez. Implementação do algoritmo de subtração de fundo para detecção de objetos em movimento, usando sistemas reconfiguráveis. 2012.

GATTASS, M. 2007. **Introdução às cores**. Disponível em <<http://www.tecgraf.puc-rio.br/~mgattass/cg/pdf/>>. Acesso em: 11 out. 2018.

GOLIBLIATAS, Renata. 2015. **A criança e a curiosidade**. Disponível em: <<http://www.passosdagravidadez.com.br/a-crianca-e-a-curiosidade/>>. Acesso em: 30 abr. 2018.

GONÇALVES, Eduardo. 2018. **O que é Raspberry Pi 3 (rpi3)**. Disponível em: <<https://www.mundotibrasil.com.br/o-que-e-o-raspberry-pi-3-rpi3/>>. Acesso em: 10 out. 2018.

GOUVEIA, Wellington da Rocha; LORENCETTI, Adriano Aparecido; OLIVETE, André Luís. 2017. Subtração de fundo em imagens digitais utilizando redes neurais artificiais MLP. **IW orkshop de Visão Computacional**, p. 36.

HOWARD, Andrew G.; ZHU, Menglong. 2017. **MobileNets: Open Source Models for Efficient On-Device Vision.** Disponível em: <<https://opensource.googleblog.com/2017/06/mobilenets-open-source-models-for.html>>. Acesso em: 10 out. 2018.

KONWAR, A. Sharmila; BORAH, B. Sagarika; TUIHUNG, C. T. An American Sign Language detection system using HSV color model and edge detection. In: **Communications and Signal Processing (ICCSP), 2014 International Conference on.** IEEE, 2014. p. 743-747.

MARENGONI, Maurício; STRINGHINI, Stringhini. Tutorial: Introdução à visão computacional usando opencv. **Revista de Informática Teórica e Aplicada**, v. 16, n. 1, p. 125-160, 2009.

MARQUES, Maria; LIMA, Atos; SANTOS, Marcelo. Protótipo de Bengala Inteligente de Baixo Custo para o Auxílio de Deficientes Visuais. In: **Anais dos Workshops do Congresso Brasileiro de Informática na Educação.** 2016. p. 1344.

MONTEIRO, Leandro Pinho. 2018. **Python: características, noções e guia de estudo.** Disponível em: <<https://universidadedatecnologia.com.br/estudo-linguagem-python-2018/>>. Acesso em: 10 out. 2018.

MOREIRA, Nelma. 2000. **Processamento de imagem.** Disponível em <<https://www.dcc.fc.up.pt/~nam/aulas/0001/pi/trabalho2/trab2/>>. Acesso em: 9 out. 2018.

MOTA, Allan. 2018. **Usando o buzzer com Arduino – Transdutor piezo elétrico.** Disponível em <<https://portal.vidadesilicio.com.br/usando-o-buzzer-com-arduino-transdutor-piezo-eletrico/>>. Acesso em: 9 out. 2018

NUTTALL, Ben. 2016. **How to build projects using the Raspberry Pi camera.** Disponível em: <<https://opensource.com/life/15/6/raspberry-pi-camera-projects>>. Acesso em: 10 out. 2018.

OPENCV. 2018. **How to Use Background Subtraction Methods**. Disponível em:<https://docs.opencv.org/master/d1/dc5/tutorial_background_subtraction.html>.

Acesso em: 11 out. 2018.

PALADINI, Fernando. 2016. **Reconhecimento de imagens: o fim da infância prolongada**. Disponível em: <<https://universoracionalista.org/reconhecimento-de-imagens-o-fim-da-infancia-prolongada/>>. Acesso em: 30 abr. 2018.

RAMÍREZ CERNA, Lourdes. Fusão de descritores de histogramas de gradientes para a detecção de faces baseado em uma cascata de classificadores. 2014.

SAYEGH, Simone. 2009. **Há várias opções para revestir a piscina, mas é preciso prestar atenção na interação do material com itens importantes, como a qualidade da água e a segurança**. Disponível em:<<http://au17.pini.com.br/arquitetura-urbanismo/188/artigo155944-3.aspx>>. Acesso em: 11 out. 2018.

SZPILMAN, David. 2015. **Afogamento – Boletim epidemiológico no Brasil**. Disponível em: <http://www.sobrasa.org/new_sobrasa/arquivos/baixar/AFOGAMENTOS_Boletim_Brasil_2015.pdf>. Acesso em: 30 abr. 2018.

ZIVKOVIC, Zoran. Improved adaptive Gaussian mixture model for background subtraction. In: **Pattern Recognition, 2004. ICPR 2004. Proceedings of the 17th International Conference on**. IEEE, 2004. p. 28-31.